비전 언어 모델(VLM) 기반 계층적 비디오 분석을 통한 멀티트랙 사운드 메타데이터 생성 파이프라인 개발

박광웅, 조영우, 차수환, 최재원, 장두성
서강대학교 경영학과, 서강대학교 컴퓨터공학과, 서강대학교 인공지능학과

Introduction

연구 목표

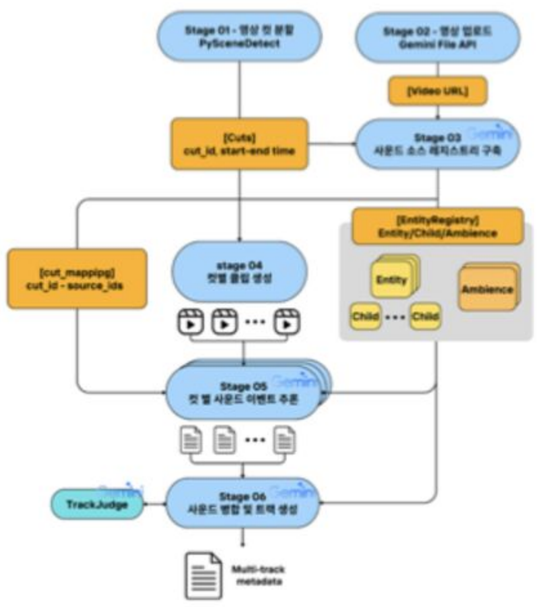
- 기존 Video-to-Audio 모델은 영상에 맞는 오디오를 생성하지만, 대부분 단일 트랙 waveform만 제공하여 실제 사운드 디자인 편집에 한계가 있다.
- 기존 Multi-track Audio 서비스는 영상을 단순 텍스트 캡셔닝으로 변환하여 Text-to-Audio 를 통해 오디오를 생성한다. 이 과정에서 구체적인 영상 정보 및 정확한 시점 정보가 손실 된다.
- 본 연구는 영상에서 구조화된 멀티트랙 메타데이터를 추출하는 것을 목표로하며, 영상 속 사운드 발생원을 구조화하고 반복 이벤트를 트랙 단위로 병합함으로써, 편집 가능한 멀티트랙 사운드 메타데이터 생성을 달성한다.

주요 기여점

1. VLM 기반 영상 분석을 통해 사운드 발생원과 이벤트를 자동 식별
2. 사운드 소스 레지스트리 구축을 통한 동일 사운드 소스의 일관성 유지
3. 사운드 메타데이터 기반 병합을 통해 반복 이벤트를 하나의 트랙으로 구성
4. Text-to-Audio/Video-to-Audio 모델 라우팅이 가능한 구조화된 사운드 메타데이터 제공

Pipeline

플로우차트



그림[1] 파이프라인 플로우차트

주요 프레임워크

영상 컷 분할

입력 영상이 길어질수록 VLM의 비디오 분석 품질이 저하되기에, 영상을 먼저 컷 단위로 분할한다. 컷 분할 라이브러리인 PySceneDetect를 사용하여 빠르고 안정적인 컷 분할을 구현하였다.

전역 영상 분석 및 사운드 소스 레지스트리 구축

영상 전체를 분석하여 소리를 발생시킬 수 있는 시각적 요소를 식별한다. 식별된 사운드 소스는 다음 세 가지 유형으로 구조화한다.

- Entity: 기본 사운드 발생원
- Entity Child: 상위 Entity에 속하지만 독립적인 사운드를 발생시키는 하위 요소
- Ambience: 공간, 장소, 배경에서 발생하는 지속적 환경음

이 과정에서 EntityRegistry와 cut_mapping을 생성한다. EntityRegistry는 영상 전체의 사운드 소스 목록을 관리하고, cut_mapping은 각 컷에 어떤 사운드 소스가 등장하는지 기록한다. 이를 통해 후속 컷별 추론 단계에서 사운드 소스 누락을 줄이고 분석 일관성을 높인다.

컷별 사운드 이벤트 추론

각 컷에 대해 발생 가능한 사운드 이벤트를 추론한다. cut_mapping을 함께 제공하여 해당 컷에 등장하는 사운드 소스를 기준으로 이벤트를 생성한다.
각 이벤트는 다음과 같은 구조로 표현된다.

사운드 소스	사운드 유형	이벤트 타입	타임스탬프	Sound Description
유발 소스	sfx /ambience	onset /continuous	발생 시간	사운드 묘사

표[1] 사운드 이벤트 출력 구조

사운드 병합 및 최종 트랙 메타데이터 생성

컷별로 생성된 이벤트 중 동일한 트랙으로 생성 가능한 후보를 병합한다.

- 1차 병합: 사운드 소스, 사운드 유형, 이벤트 타입이 모두 같은 이벤트를 묶는다.
- 2차 병합: Sound Description이 서로 다른 경우에는 Gemini Flash 기반 TrackJudge를 호출하여 실제로 같은 트랙으로 유지할지, 별도 트랙으로 분리할지 판단한다.

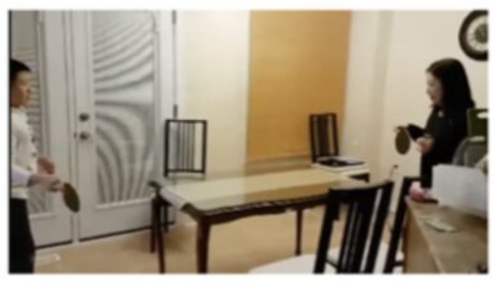
TrackJudge는 사운드의 물리적 발생 메커니즘이 명확히 다른 경우에만 별도 트랙으로 분리한다. 최종 메타데이터 구조는 아래와 같다.

Track ID	사운드 소스	사운드 유형	이벤트 타입	타임스탬프	Sound Description

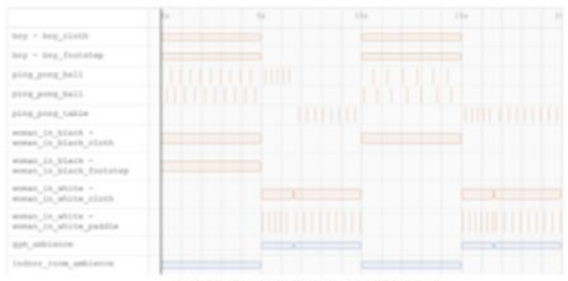
표[2] 멀티트랙 메타데이터 구조

Experiments

실험 결과



그림[2] VGGsound 영상 샘플



그림[3] 메타데이터 시각화 결과

VGGsound 샘플에 대한 실험 결과, 영상은 6개의 컷으로 분할되었다. 104개의 사운드 이벤트가 추출되었고 최종 11개의 트랙으로 병합되어 멀티트랙 메타데이터가 생성되었다. 이는 본 파이프라인이 영상 내용을 단순 나열하는 것이 아닌 멀티트랙 오디오 생성을 위 한 구조적 메타데이터를 생성할 수 있음을 보여준다. 그림 3은 샘플 영상에 대해 생성된 메타데이터를 시각화하여 배치한 것이며, 표 5, 6은 메타데이터 생성 결과이다.

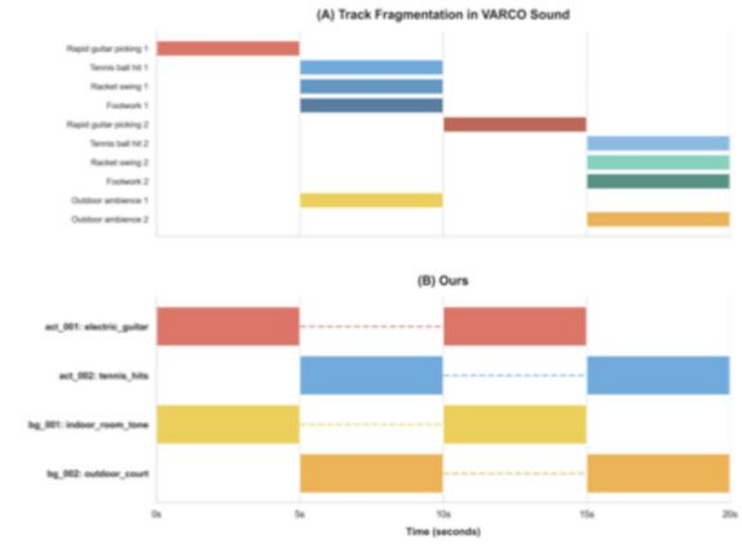
Track ID	사운드 소스	사운드 유형	이벤트 타입	타임스탬프
Track 01	boy_cloth	sfx	continuous	0.0~5.0s, 10.0~15.0s
Track 03	ping_pong_ball	sfx	onset	0.5s, 0.9s, ...
Track 05	ping_pong_table	sfx	onset	6.9s, 7.3s, ···
Track 11	indoor_room	ambience	continuous	0.0~5.0s, 10s~15s

표[3] 멀티트랙 메타데이터 생성 결과

ID	Sound Description
Track 01	Subtle rustle of a cotton sweatshirt during movement
Track 03	Quick, sharp bounce of a ping pong ball on a hard wooden table
Track 05	The crisp, hollow sound of a ping pong ball bouncing on the table
Track 11	Quiet indoor room tone of a dinig area

표[4] 각 트랙에 대한 Description 결과

비교 실험 결과



그림[4] 각 트랙에 대한 Description 결과

상용서비스인 VARCO Sound와 비교실험을 수행하였다. 본 논문의 기법은 두 가지 측면에서 구조적 차별성을 가진다.

1. 흩어진 반복 사운드를 단일 트랙으로 병합하여 시간 적 일관성 보장이 가능하다.
2. 조건부 모델 라우팅을 통한 비디오-오디오 시간 정렬에 기여할 수 있다.

Conclusions

1. VLM 기반 계층적 비디오 분석을 통해 영상으로부터 멀티트랙 사운드 메타데이터를 자동 생성하는 파이프라인을 구현
2. 사운드 소스 식별, 컷별 이벤트 추론, 트랙 병합을 통해 기존 단일 트랙 오디오 생성 방식의 편집 한계를 보완
3. 향후 정량 평가 지표와 사용자 평가를 도입하여, 실제 사운드 디자인 워크플로우에서의 활용 가능성을 검증할 계획

References
[1] Y. Zhang et al., "Foleycrafter: Bring silent videos to life with lifelike and synchronized sounds," Int. J. Comput. Vis., vol. 134, no. 1, p. 46, 2026.
[2] H. K. Cheng, M. Ishii, A. Hayakawa, T. Shibuya, A. Schwing, and Y. Mitsufuji, "Mmaudio: Taming multimodal joint training for high-quality video-to-audio synthesis," Proc. CVPR, pp. 28901-28911, 2025.
[3] S. Yoo, A. Hernandez Santisteban, P. Seetharaman, J. Salamon, O. Nieto, and A. Truong, "SoundStager: Interactive Design of Story-Driven GenAI Soundscapes for Video," Proc. CHI, pp. 1-26, 2026.
[4] NC AI, "VARCO Sound," [Online]. Available: https://sound.varco.ai. [Accessed: Apr. 2026].
[5] H. Chen, W. Xie, A. Vedaldi, and A. Zisserman, "Vggsound: A large-scale audio-visual dataset," Proc. ICASSP, pp. 721-725, 2020.

- 본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 AI중심대학사업(2026-0-00036)과 멀티모달 AI에이전트 시대에 적합한 실무형 AI인재육성프로그램(RS-2025-25441313)의 지원을 받아 수행되었음