SoundPilot

멀티트랙 사운드 디자인을 위한 Tool-calling 에이전트 시스템



팀명: sogang V2A

구성: 서강대학교 경영학과 박광웅 외 2인

서강대학교
AI중심대학사업단

개발배경

산업 전반의 대규모 수요와 기존 작업의 어려움

다양한 분야에서 사운드를 필요로 하지만, 장면에 맞는 사운드를 기획하고 편집하려면 많은 시간과 전문성이 필요합니다

1. 폭발적으로 성장하는 콘텐츠 시장

2,000만+

하루에 Youtube 업로드되는 영상 개수

20만 건 / day

사운드 작업이 필요한 영상을 1%라고 가정했을 때 잠재적 사운드 디자인 수요

전문 스튜디오부터 1인 크리에이터까지 영상 제작 주체 확대

2. 다양한 산업에서의 사운드 수요



광고·마케팅 — 91% 기업의 영상 마케팅 활용 비율



게임·애니 — 2만+ 25년 Steam 출시 게임



영화·드라마 — 597편 25년 Netfilx 신규 작품 수



교육·소개자료 — 1.35만+ 25년 Coursera 강좌

다양한 산업 분야에서의 사운드 수요

3. 여전히 어려운 사운드 디자인

복잡한 사운드 디자인 과정

필요한 사운드 결정 → 사운드 탐색 및 제작
→ Timeline 배치 → 레이어링 & 믹싱 → 검토 & 수정

비전문가 개인 크리에이터, 개발자, 마케터

어떤 소리를 넣어야 할지부터 어렵습니다.

전문가 전문 스튜디오, 사운드 엔지니어

반복적인 초안 작업에 시간이 소요되어
창의적 작업에 집중하기 어렵습니다.

모두에게 어려운 복잡한 사운드 디자인 과정

누구나 빠르고 쉽게 사용 가능하며 실제 산업현장에 활용 가능한 사운드 제작 환경이 필요합니다.

출처: 광고·마케팅 - {Wyzowl, Video Marketing Statistics 2024}, 게임·애니메이션 - {SteamDB, 2025}, 영화·시리즈 - {What's on Netflix, 2026.01},
교육·소개자료 - {Coursera 2025 Form 10-K}, YouTube 영상 - {YouTube Official Blog, 2025.04}

목표 시스템

기존 AI의 한계와 목표 시스템

기존 AI의 한계를 넘어 영상에 맞는 편집 가능한 멀티트랙 사운드를 생성합니다

기존 사운드 생성 AI의 한계

1. 원하는 소리만 따로 편집하기 어렵습니다

- 영상 속 모든 사운드가 하나로 뭉개져서 생성 → 특정 소리만 편집하기 어려움

2. 영상의 동작과 사운드 타이밍이 어긋납니다

- 영상을 텍스트로 요약하며 세밀한 움직임 정보가 손실 → 품질↓, 타이밍 불일치

3. 사운드 생성의 근거가 명확하지 않습니다

- AI or 추상적 임베딩에 의존 → 단순히 그럴듯하게 생성, 근거와 신뢰도 부족



목표 시스템

객체별로 개별적인 사운드 생성
↓
원하는 사운드만 따로 편집 가능

사운드 유형별 생성 모델 라우팅
↓
품질 및 영상과의 타이밍 보장

명시적인 시각 정보를 기반으로 생성
↓
해석 가능하고 신뢰도 높은 시스템

작품 구성

SOUND DESIGN AGENT SYSTEM

영상 분석부터 사운드 계획·생성까지 하나의 Agentic Workflow로 자동화합니다

1. 비디오 분석



영상에서
주요 Frame 검출

VLM으로
영상 내 객체 식별

Object Tracking

2. SoundPilot



Tool-calling을 통한
정보 수집

사운드 소스,
유형, 발생 시점 추론

Sound Timeline
조회 및 갱신

조회 및 수정

3. Sound Timeline 편집

Track: 동일한 사운드는 하나의 트랙으로

Source: 무엇이 소리를 내는지

Event: 발생 시점, 사운드 설명

4. Routing & Generation

Video-to-Audio: 액션 효과음

Text-to-Audio: 배경음 · 단발성 효과음

Text-to-Speech: 목소리, 대화

5. Multi-track Sound



개별 생성 및 편집

최적화된 생성 모델 사용

시각 근거 기반 생성

개발 세부 내용 1

비디오 분석

영상에서 필요한 장면과 객체를 효율적으로 분석하여 사운드 추론에 필요한 근거를 확보합니다

1. 영상을 scene 단위로 분할

영상에서 프레임 간 변화량이
임계값 이상인 지점을 기준으로 scene을 분리

(0-5s)

scene 1
(0-1s)



scene 2
(1-5s)



2. scene별 대표 장면 추출

중간 프레임을 우선 추출하되, 최소 1frame / 2sec
선정하여 충분한 정보를 확보하며 압축

2초 미만 scene



0.5s

2초 이상 scene



1s



3s



5s

3. 등장하는 객체 식별

추출한 대표 이미지만을 Vision-Language model
에 입력하여 영상 내 객체를 효율적으로 식별

입력



key frame

VLM

장면 분석

사운드 관련 객체를
추적 후보로 선별

출력

Object list

Red samuri
Black samuri
Sword

4. 객체 위치 및 움직임 추적

식별된 객체 정보는 객체 추적 모듈(SAM3) 로 전송
영상에서 해당 객체의 위치와 움직임을 추적

출력

객체 추적 정보

1. Bounding Box
2. Mask
3. Frame Image



5. 이벤트 추정

객체 추적 정보를 기반으로 이벤트 후보를 선정

조건	이벤트 type
객체의 Mask가 생성/사라짐	객체 등장/퇴장
객체 간 Mask 겹침	충돌 / 접촉
Mask 중심점 / 중심점 위치 변화	객체 위치 / 움직임

6. 분석 결과 구조화 및 저장

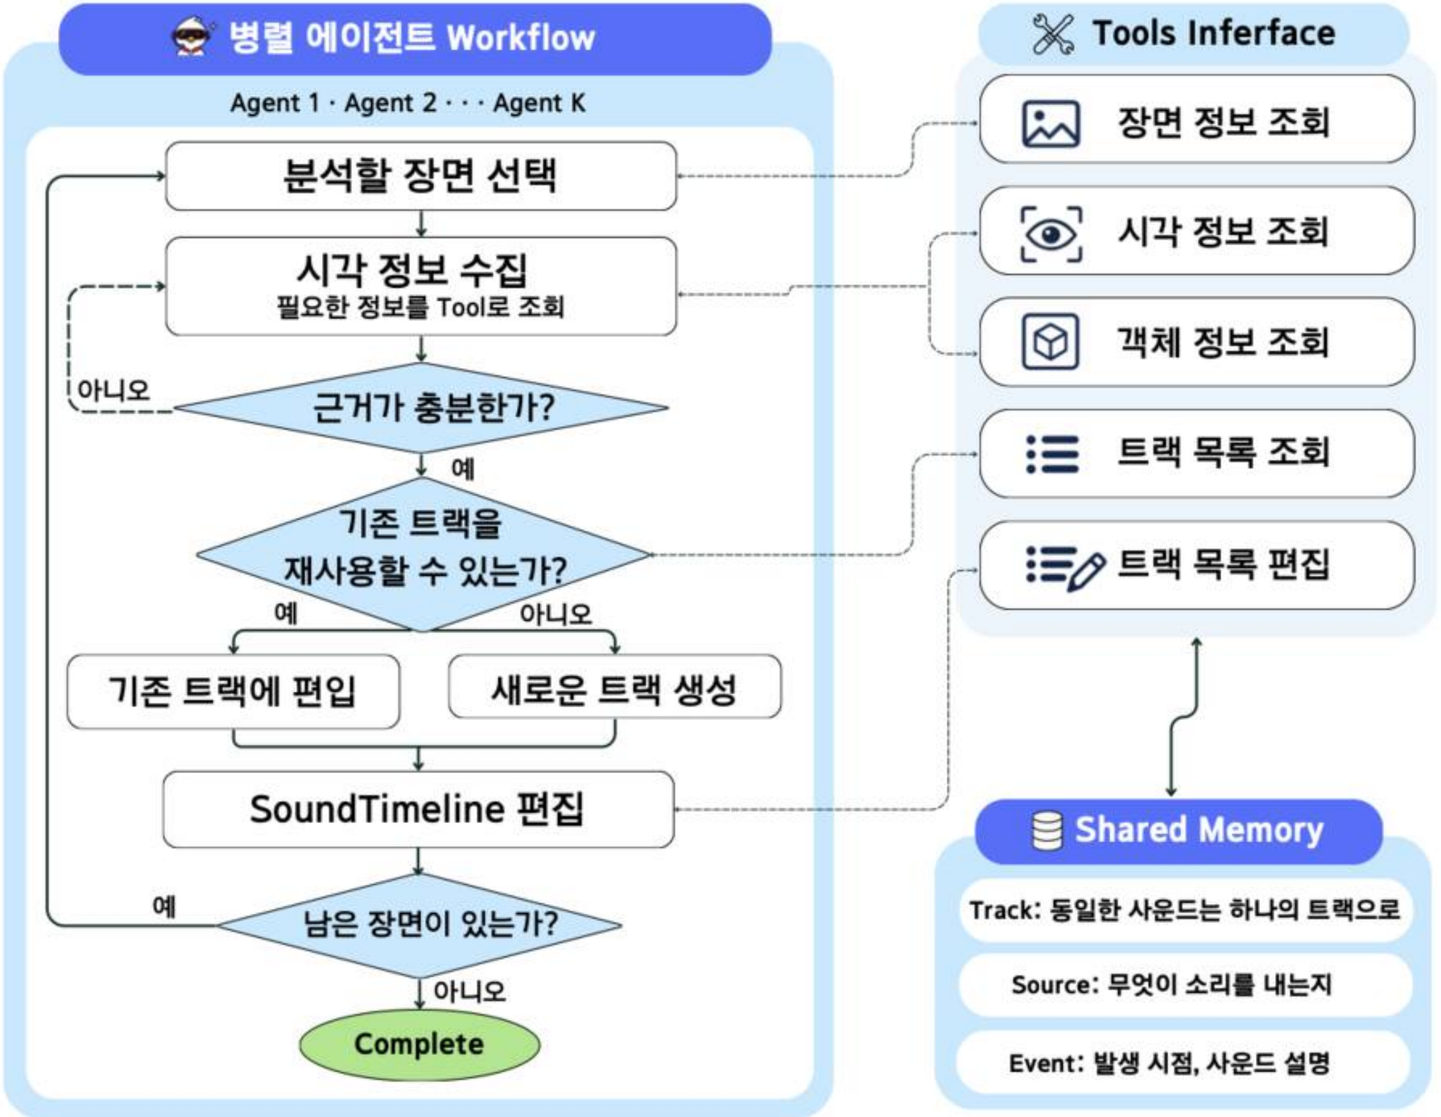
분석한 정보를 에어전트가 조회 가능한 형태로 저장
에이전트는 조회한 정보를 근거로 삼아 사운드 계획

계층	정보	활용
Scene	시작/종료 시간 대표 장면, description	현재 장면 맥락 / 배경 / 구간 확인
Object	Object list bbox / mask / image	사운드 발생 요소와 위치/움직임 확인
Event	type, 시작/종료 시간 관련된 Object	사운드 종류 / 발생시점 추론

개발 세부 내용 2

에이전트 시스템 설계

라이브러리, AI model을 tool형식으로 호출하여 영상을 분석하고 작업을 계획합니다



핵심 설계

1. Tool-calling 기반 에이전트 시스템

- 수집한 정보를 조회하며 신뢰도 있는 추론
- 모든 조회 및 편집은 주어진 Tool을 통해 수행하여 할루시네이션을 줄이고 규제된 행동 수행 가능

2. 능동적인 시간 정보 수집 전략

- 사운드 추정을 위해 충분한 근거를 모을 때까지 정보 조회를 반복
- 주변 구간의 정보를 함께 조회하여 맥락을 고려한 추론 가능

3. 공유 메모리 설계

- 여러 에이전트가 상태를 공유하며 병렬 동작
- 공유 메모리를 통해 일관성을 보장하며 생성속도 향상 가능

개발 세부 내용 3

사운드 유형별 생성 모델 라우팅

사운드 유형에 따라 최적의 생성 모델을 선택합니다.



1. 액션 효과음

- 특성: 영상 속 동작과 소리의 발생 시점이 일치해야 함
- 모델: 움직임과 타이밍을 반영해 생성하는 V2A 모델 사용

2. 배경음·음악

- 특성: 영상에 보이지 않는 배경 사운드 필요 / 개별 동작보다 사용자가 의도한 분위기가 중요
- 모델: 원하는 사운드와 분위기를 텍스트로 지정하는 T2A 모델 사용

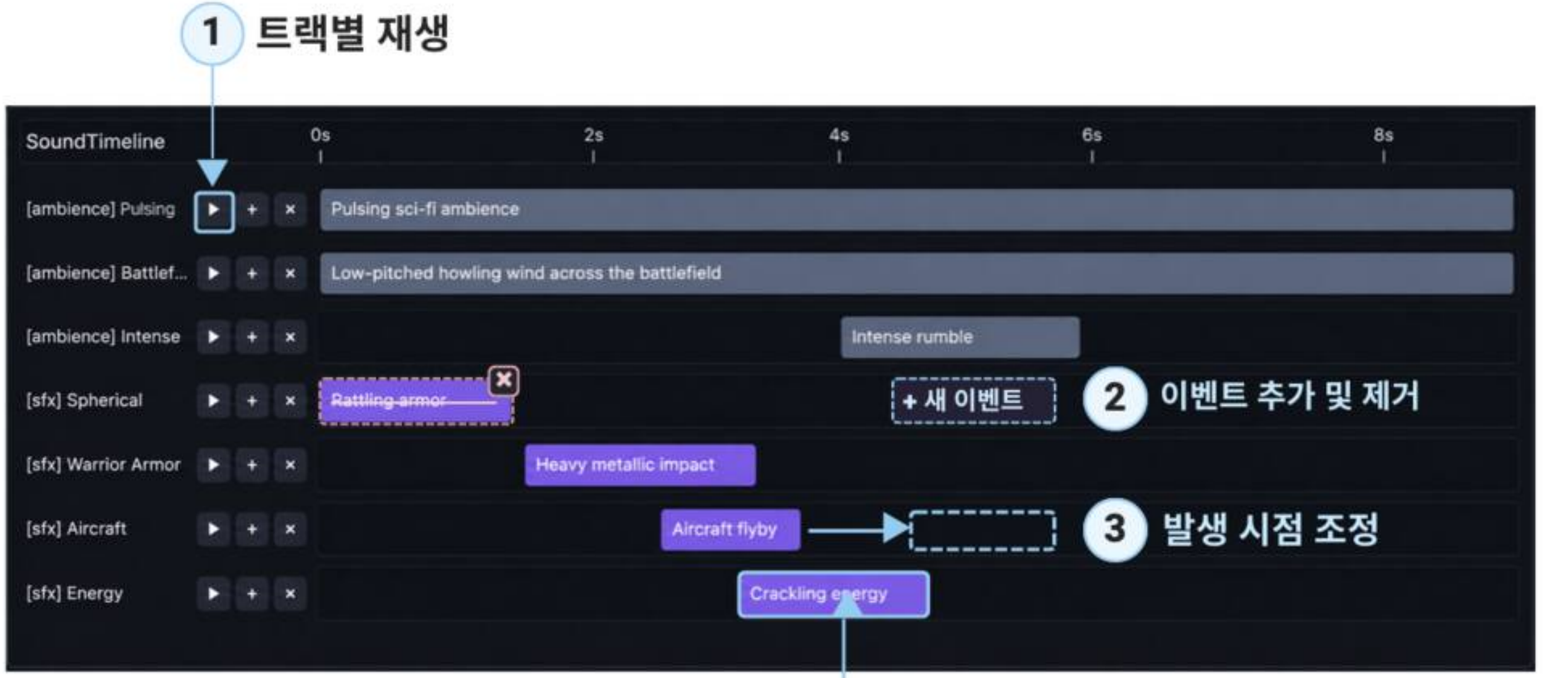
3. 대사·음성

- 특성: 정확한 대사 전달과 자연스러운 발음·억양이 중요
- 모델: 작성한 대본을 음성으로 변환하는 TTS 모델 사용

개발 세부 내용 4

사운드 타임라인 편집

AI 결과를 실제 사용자가 검토하며 보완할 수 있습니다.



1. 트랙별 개별 청취

각 트랙을 개별 재생하여
생성된 사운드를 확인

2. 이벤트 추가 및 제거

이벤트를 새로 추가하거나 잘못 만들어진
이벤트 제거 가능

3. 발생 시점 조정

사운드 블록을 이동하여
영상 속 동작과 타이밍 조정

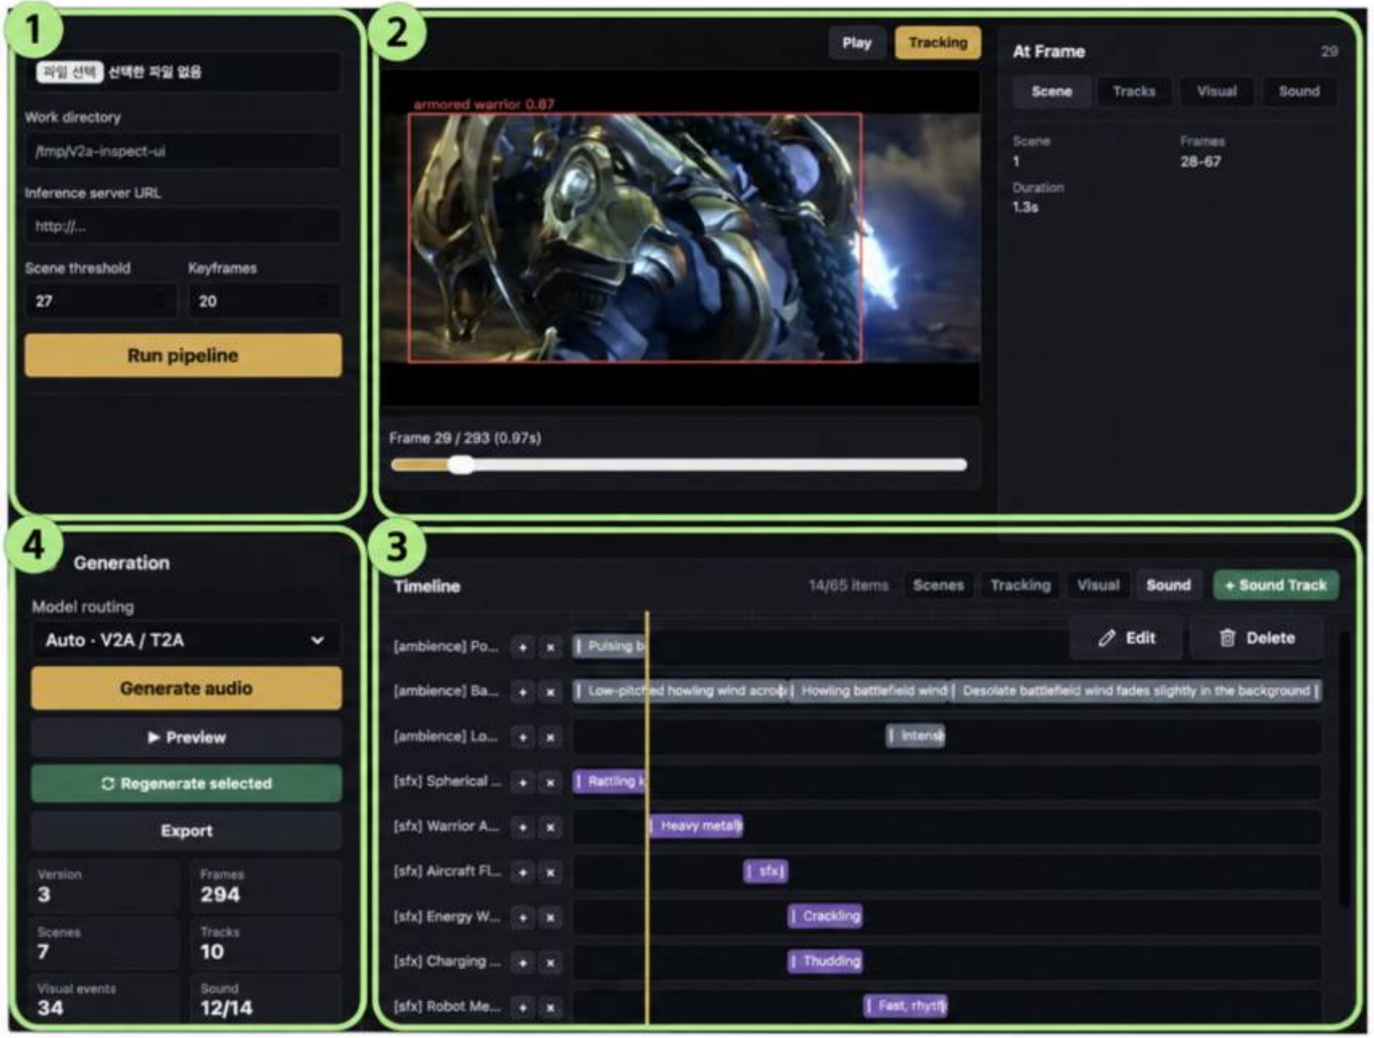
4. 텍스트 편집 후 재생성

사운드 설명을 직접 수정
수정된 텍스트로 재생성 가능

구현 결과

시스템 UI

영상 분석부터 사운드 생성·편집까지 한 화면에서 수행 가능합니다.



1. UPLOAD

영상 업로드 시 주요 장면 검출과 객체 추적이 자동으로 시작됩니다

2. PLAN

에이전트가 분석 정보와 현재 상태를 조회하며 사운드 디자인을 계획합니다.

3. EDIT

만들어진 초안을 검토하고 수정합니다.
불필요한 사운드를 제거하거나 누락된 사운드를 추가 배치 가능합니다.

4. Generation

선택된 생성 모델로 사운드를 생성합니다.
사운드를 들어보며 개별 편집 및 재생성이 가능합니다.

구현 결과

실행 결과

영상 분석부터 사운드 생성·편집까지 한 화면에서 수행 가능합니다.

검 전투 장면

17.2초 영상 · 7개 트랙 · 36개 이벤트



0.4초 6.0초 16.4초

생성된 사운드



1. 사운드 별 개별 생성

총 7개의 사운드를 개별 트랙으로 생성
→ 개별 편집과 일관된 사운드 구성 가능

2. 사운드 유형 판단 및 라우팅

각 사운드의 성격에 따른 유형 판단
→ 사운드 특성에 맞는 생성 모델 활용 가능

3. 실제 제작에 활용 가능한 초안

효과음·대사·환경음·배경 음악을 함께 구성
→ 레이어링·믹싱의 시작점으로 활용

기대효과

사운드 디자인을 더 쉽고 빠르게

비전문가의 진입 장벽을 낮추고, 전문가의 반복 작업을 줄입니다.

기존 제작 과정

필요한 사운드 결정 → 사운드 제작·배치 → 검토·수정

필요한 소리 결정부터 생성·배치까지 직접 수행 필요

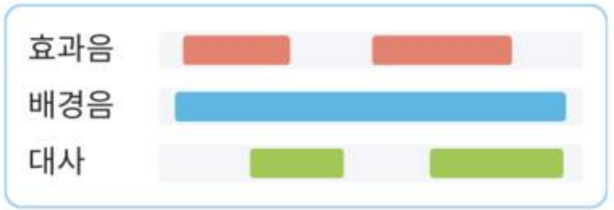
SoundPilot 활용

사운드 초안 자동 생성

시각 근거 기반 사운드 계획
영상 동작·타이밍을 반영한 생성

→

편집 가능한 멀티트랙



↓

개별 편집 · 레이어링 · 믹싱

1. 비전문가의 진입 장벽 완화

필요한 사운드를 계획·생성까지 자동화
사운드 디자인 전문 작업 부담 완화

2. 전문가의 반복 작업 감소

사운드 계획·생성·배치 자동화
반복적 초안 작업을 줄이고 창의적 작업에 집중

3. 실제 제작 워크플로우에 통합

소스별로 분리된 멀티트랙 사운드 제공
원하는 소리의 내용·타이밍만 개별 편집
기존 사운드 디자인 워크플로우에 적용 가능

단순한 AI 모델이 아닌
실제 워크플로우에 통합 가능한 에이전틱 시스템

감사합니다.