

Sound Design Agent

멀티트랙 사운드 디자인을 위한 Tool-calling 에이전트 시스템

서강대학교 AI중심대학사업단

[팀명] soganaV2A
[팀원] 박광웅 외 3인
[지도교수] 장두성
[협력기업] LG유플러스 볼트업

과제목적

영상만 있으면, 편집 가능한 멀티트랙 사운드 디자인을 자동으로!

하루 5,000만개의 숏폼, 연간 20,000개의 새로운 게임이 전세계에서 생성.

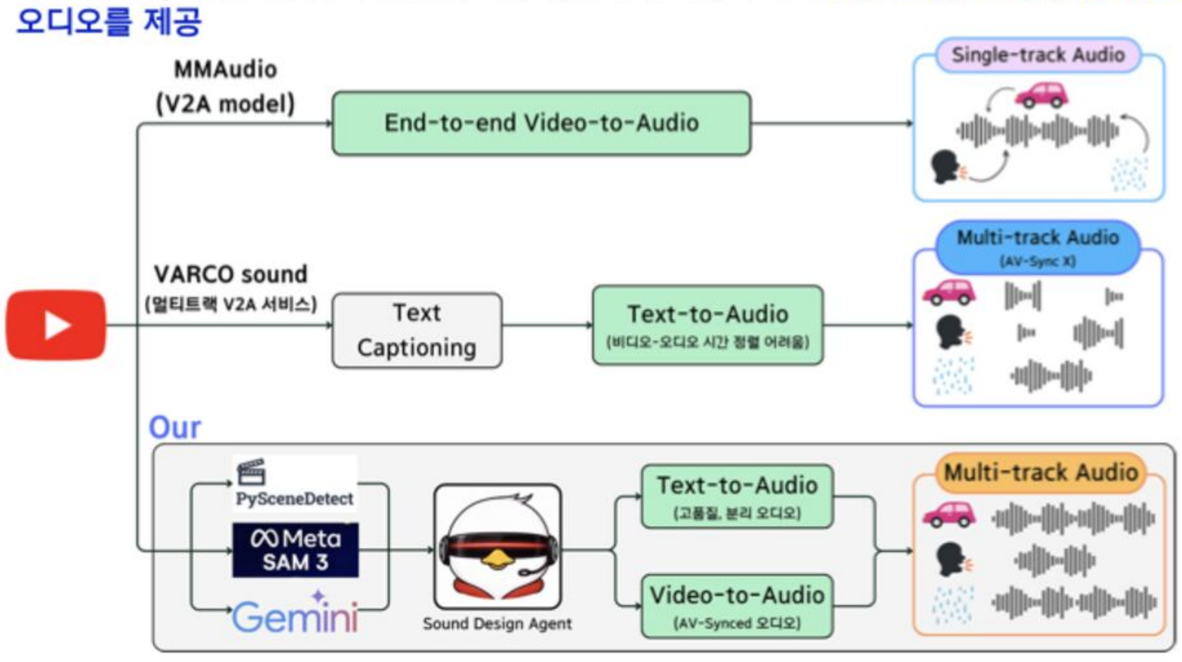
YouTube 14M Shorts / day　TikTok 36M Videos / day　STEAM 20K Games / year

숏폼 영상의 사운드 필요 비율을 10%, 게임당 20개의 사운드 필요를 가정하면, **하루 약 500만 건의 사운드 디자인 수요가 발생**

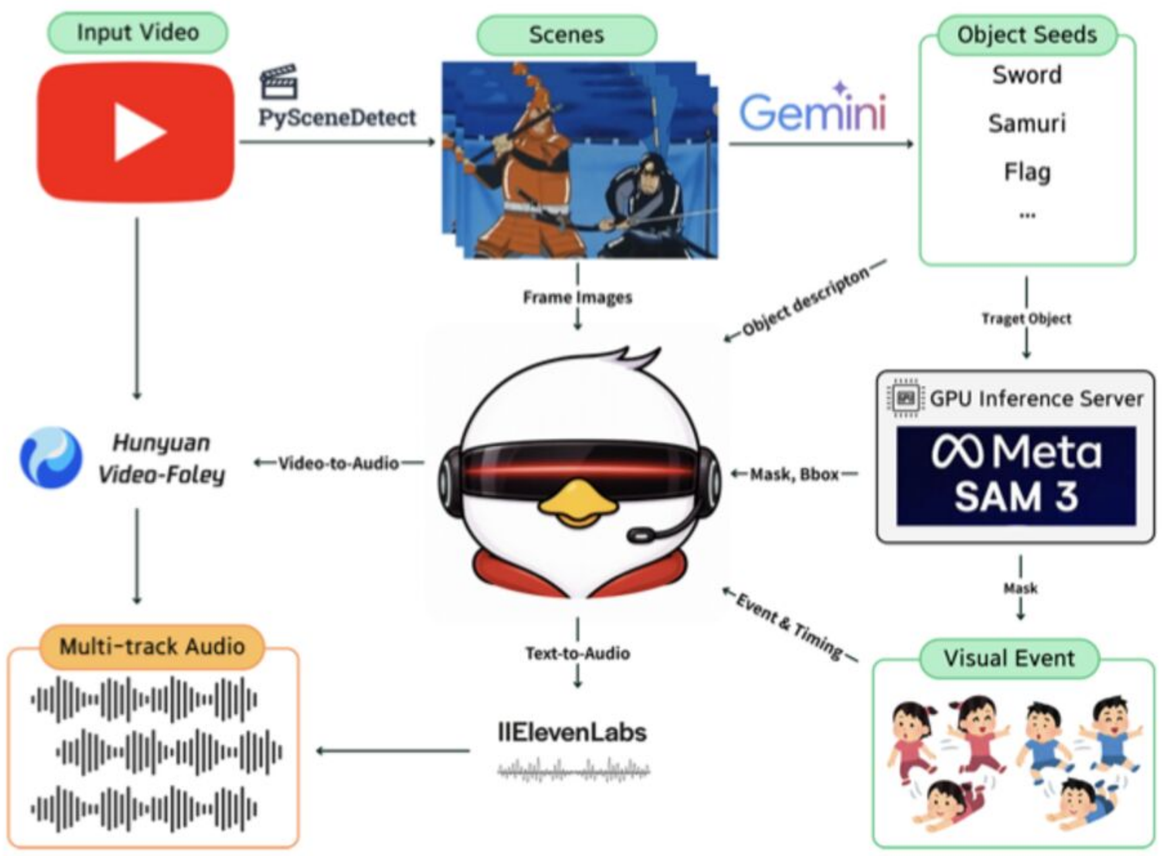
개인 크리에이터와 인디 게임 개발자들에게 사운드 디자인은 비용과 시간 부담

기존 서비스는 모든 사운드가 하나로 뭉친 Single-Track Waveform으로 생성되어 특정 요소를 개별적으로 편집할 수 없다. (전투 장면에서 발소리만 증폭 or 배경음만 줄이기 불가)

Sound Design Agent는 영상 속 객체를 식별·추적하며 시각 증거를 능동적으로 조회하는 에이전트로, 사운드를 트랙 단위로 자동 생성하여 사용자가 **자유롭게 편집가능한 멀티트랙 오디오를 제공**



과제내용



추론 효율성을 위한 Key frame only 분석 전략

PySceneDetect 기반 scene 분할과 대표 키프레임 추출 &
scene별 소수 프레임만 VLM에 전달함으로써 추론 효율성 증대

유사한 장면을 모두 처리하는 것이 아닌, 주요 프레임만 추출하여 분석 진행하여 영상 전체를 LLM에 입력했을 때 비용이 폭발하고 지연이 발생하는 것을 방지

SAM3 기반 객체 추적 및 사운드 타임라인 초안 생성

영상에 등장하는 객체를 식별하고 프레임 단위로 추적 &
객체 Mask를 기반으로 객체의 등장·접촉·이동 시점이 프레임 단위로 계산

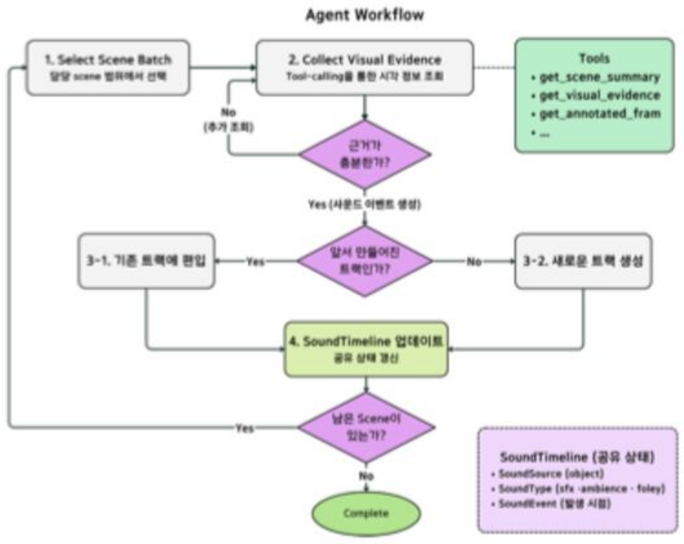
기존 서비스가 영상 프레임의 임베딩 정보만으로 오디오를 추정하는 것과 달리, 프레임 단위 객체 추적을 통해 **"특정 객체의 특정 동작 시점"에 정확히 정렬**된 오디오를 생성



*SAM 3 (Segment Anything with Concepts): Meta AI가 개발한 객체 인식 모델, 텍스트만으로 영상 속 객체를 식별하고 프레임 단위로 추적할 수 있다.

Tool-Calling 에이전트 병렬 추론 파이프라인 설계

LangChain 기반으로 에이전트에게 정보 조회/상태 확인/트랙 편집 Tool 제공
4개의 Agent workers가 병렬 동작함으로써 작업시간 획기적 단축
에이전트간 동기화를 위한 중앙 관리 상태를 구현

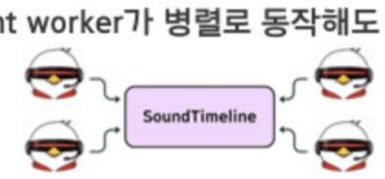


Agent Workflow
1. Scene별 Key frame 정보 조회
2. 정보가 충분하지 않다면 주변 프레임 정보 요청
3. 정보를 종합해 사운드 종류·발생시점 추론 및 description 작성

Tools
- 정보 조회 — scene summary, visual events, annotated frame
- 상태 확인 — SoundTimeline source·track·event 조회
- 트랙 편집 — sound source/track/event 생성·갱신

상태 확인 Tools 기반 트랙 재사용 정책을 통해 여러 Agent worker가 병렬로 동작해도 영상 전체의 사운드 일관성이 자동 유지

1. 새 사운드 이벤트 기록 전 기존 트랙과 동일한지 확인
2. 동일하면 기존 트랙에 편입, 다르면 새 트랙 생성



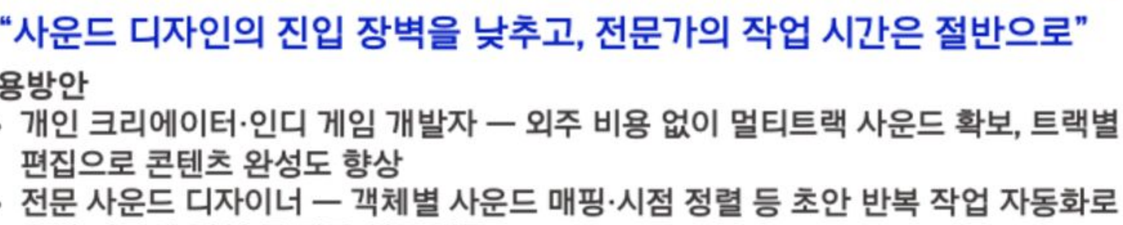
→ 같은 객체의 동일한 사운드는 **발생 시점이 달라도 동일 트랙으로 일관되게 유지**

동적 모델 라우팅을 통한 오디오 생성 최적화

사운드 특성에 따라 생성 모델을 자동으로 라우팅하는 동적 구조를 구현하여 단일 모델로는 동시에 달성할 수 없는 품질과 효율을 함께 확보

종류	특징	사용 모델
Video-to-Audio	영상과 오디오의 시간 동기화에 강하지만, 분리된 오디오 생성이 어려움	Hunyuan Video-Foley
Text-to-Audio	고품질의 분리된 오디오를 빠르게 합성 가능하지만, 영상과 시간 정렬 어려움	IIElevenLabs

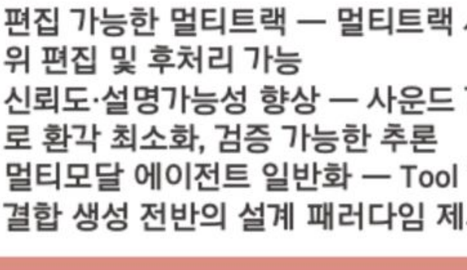
사운드 이벤트의 종류를 분석해 비디오 동기화가 중요한 이벤트(객체 반복 충돌·액션)는 V2A로, 시작·종료·발생 시점이 명확한 이벤트(ambience·배경음)는 T2A로 라우팅하여 독립 생성한 뒤, 통합하여 최적화된 멀티트랙 사운드를 구축

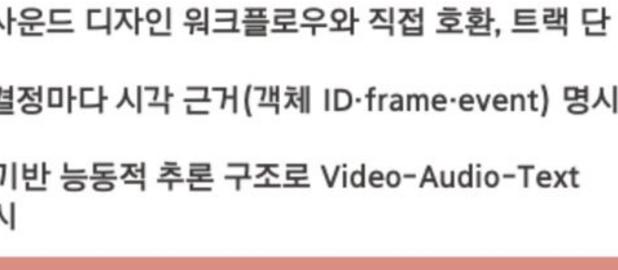


결과물

웹 UI를 통해 전체 기능 제공
영상 업로드 → 추론 시작 → SoundTimeline 생성 → 사용자 편집

[웹 UI]　[SoundTimeline]





웹 데모　생성 결과 및 시연 영상

기대효과

"사운드 디자인의 진입 장벽을 낮추고, 전문가의 작업 시간은 절반으로"

활용방안
- 개인 크리에이터·인디 게임 개발자 — 외주 비용 없이 멀티트랙 사운드 확보, 트랙별 편집으로 콘텐츠 완성도 향상
- 전문 사운드 디자이너 — 객체별 사운드 매핑·시점 정렬 등 초안 반복 작업 자동화로 음색 디자인·믹싱 등 전문 업무 집중
- 콘텐츠 플랫폼 (B2B) — 영상 편집 도구·게임 엔진에 API로 통합 가능, 숏폼·광고·게임의 대량 사운드 디자인 자동화

기여점
- 편집 가능한 멀티트랙 — 멀티트랙 사운드 디자인 워크플로우와 직접 호환, 트랙 단위 편집 및 후처리 가능
- 신뢰도·설명가능성 향상 — 사운드 결정마다 시각 근거(객체 ID·frame·event) 명시로 환각 최소화, 검증 가능한 추론
- 멀티모달 에이전트 일반화 — Tool 기반 능동적 추론 구조로 Video-Audio-Text 결합 생성 전반의 설계 패러다임 제시