# 딥러닝 프로젝트

1조

TABLE OF CONTENTS

# 목차 안내


01 문제 의식 및 목표 소개

02 데이터 소개 및 전처리

03 피쳐 엔지니어링

04 모델

05 모델 - ViT

06 모델 - LSTM

07 모델 간 비교

08 결론 및 한계점

09 Q&A

1

# 주제 소개 - 홈트레이닝 AI 코치
# 운동 자세 분석 및 피드백 시스템




- 최근 일반인들의 운동 관심 증대
- 홈 트레이닝 도우미 어플
- 비싼 PT 대체







LSTM VS ViT

피처엔지니어링 작업 여부, 모델 종류에 따른 성능 비교

2

# 데이터 소개






**AI HUB 피트니스 자세 이미지**

5개의 카메라를 이용하여 촬영한 사진의 각 관절 좌표 값 존재

2

# 데이터 소개

각 관절 (x,y) 좌표 값

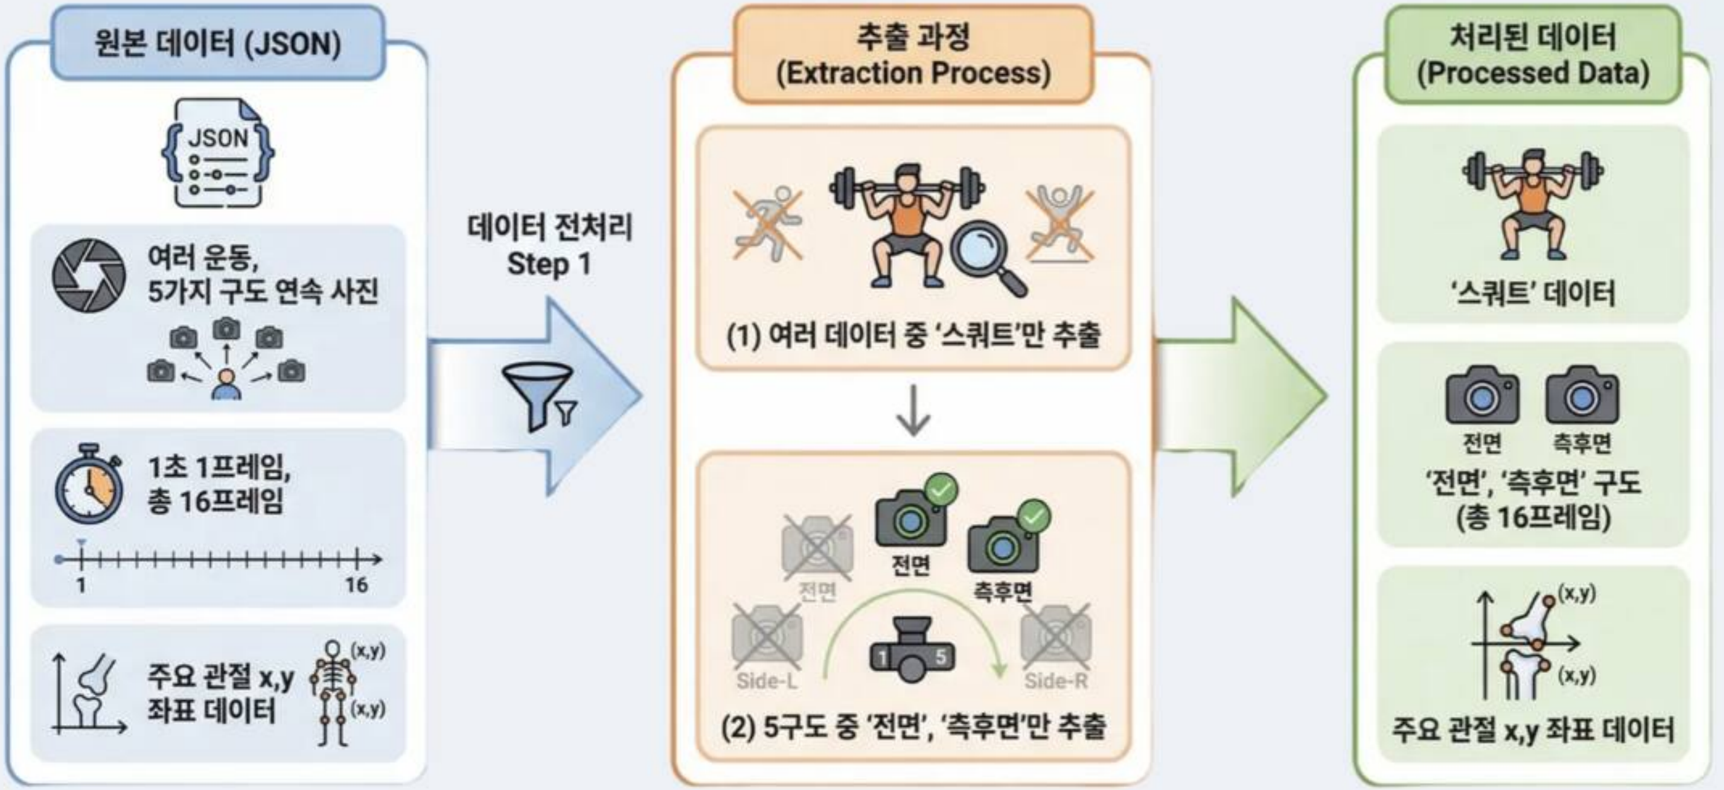

```
{
    "frames": [
        {
            "view1": {
                "pts": {
                    "Nose": {
                        "x": 1030,
                        "y": 388
                    },
                    "Left Eye": {
                        "x": 1015,
                        "y": 367
                    },
                    "Right Eye": {
                        "x": 1029,
                        "y": 381
```


라벨링 T/F 값


```
    "type_info": {
        "key": "314",
        "type": "바벨/덤벨",
        "pose": "선 자세",
        "exercise": "바벨 스쿼트",
        "conditions": [
            {
                "condition": "척추의 중립",
                "value": false
            },
            {
                "condition": "고개 정면",
                "value": true
            },
            {
                "condition": "발과 무릎의 방향 일치",
                "value": true
            },
            {
                "condition": "발바닥 지면 고정",
                "value": true
            }
        ],
        "description": "척추 말린상태"
    }
}
```

3

# 데이터 전처리 1) 데이터 추출



3

# 데이터 전처리 2) 데이터 증강

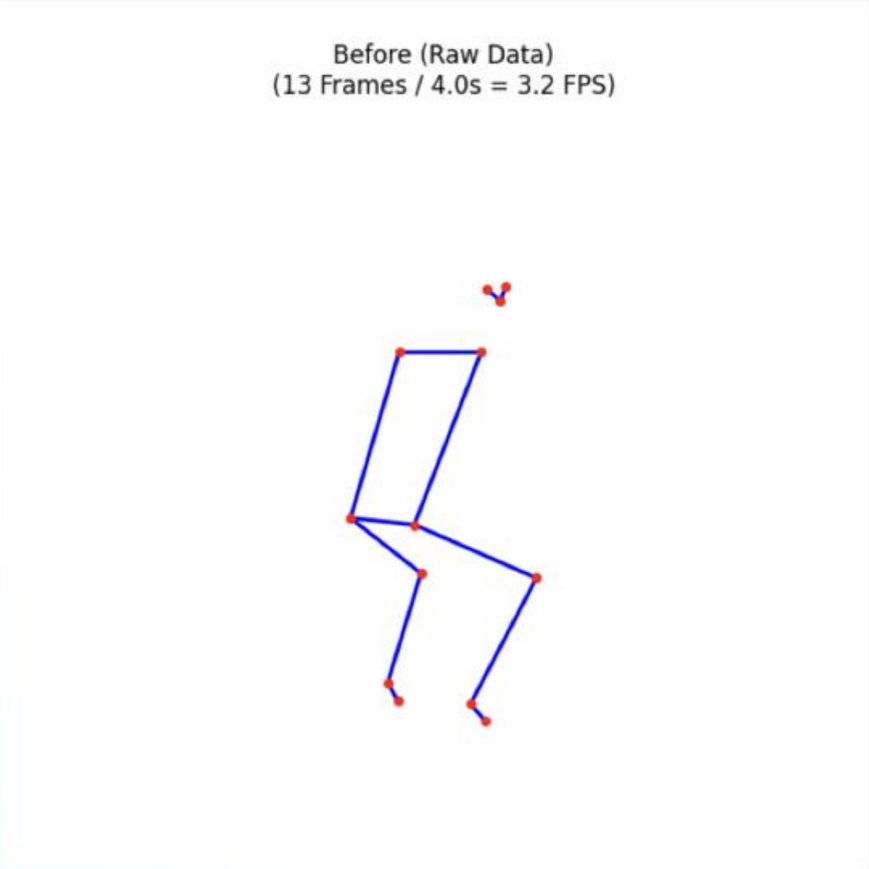
보간 + 스무딩을 통한 데이터 증강

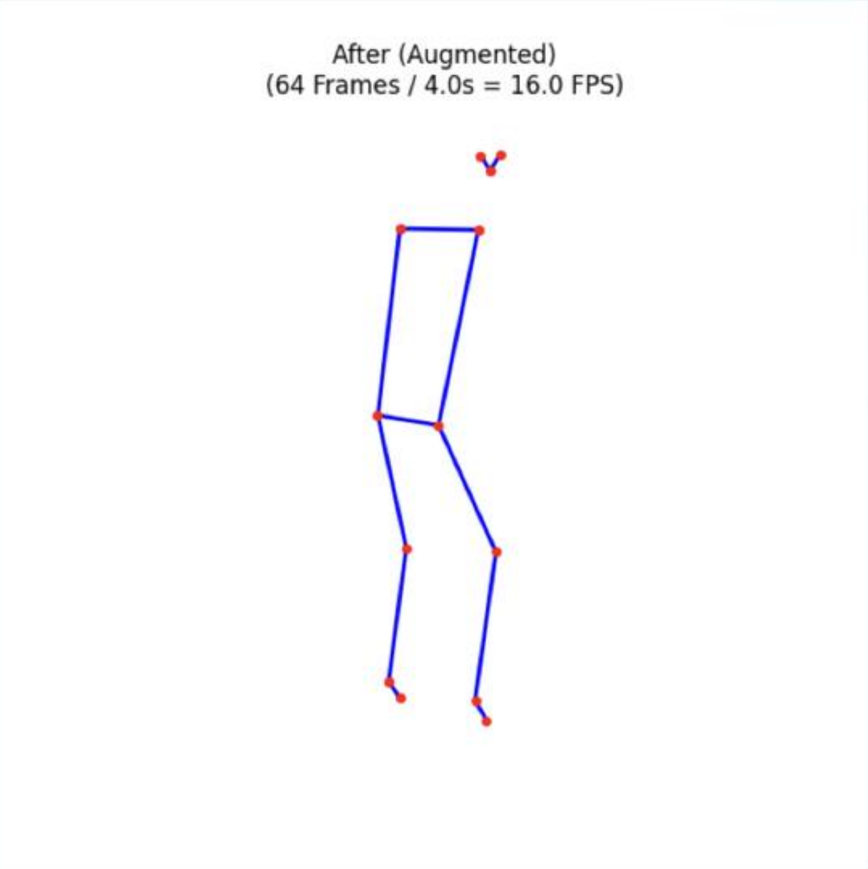
| 과정 | 결과 |
| --- | --- |
| • 선형 보간<br>• 스무딩 | 기존 16프레임 -> 64프레임 |

좌표 변화를 부드럽게 하여, 정확한 정보를 담기 위한 목적

3

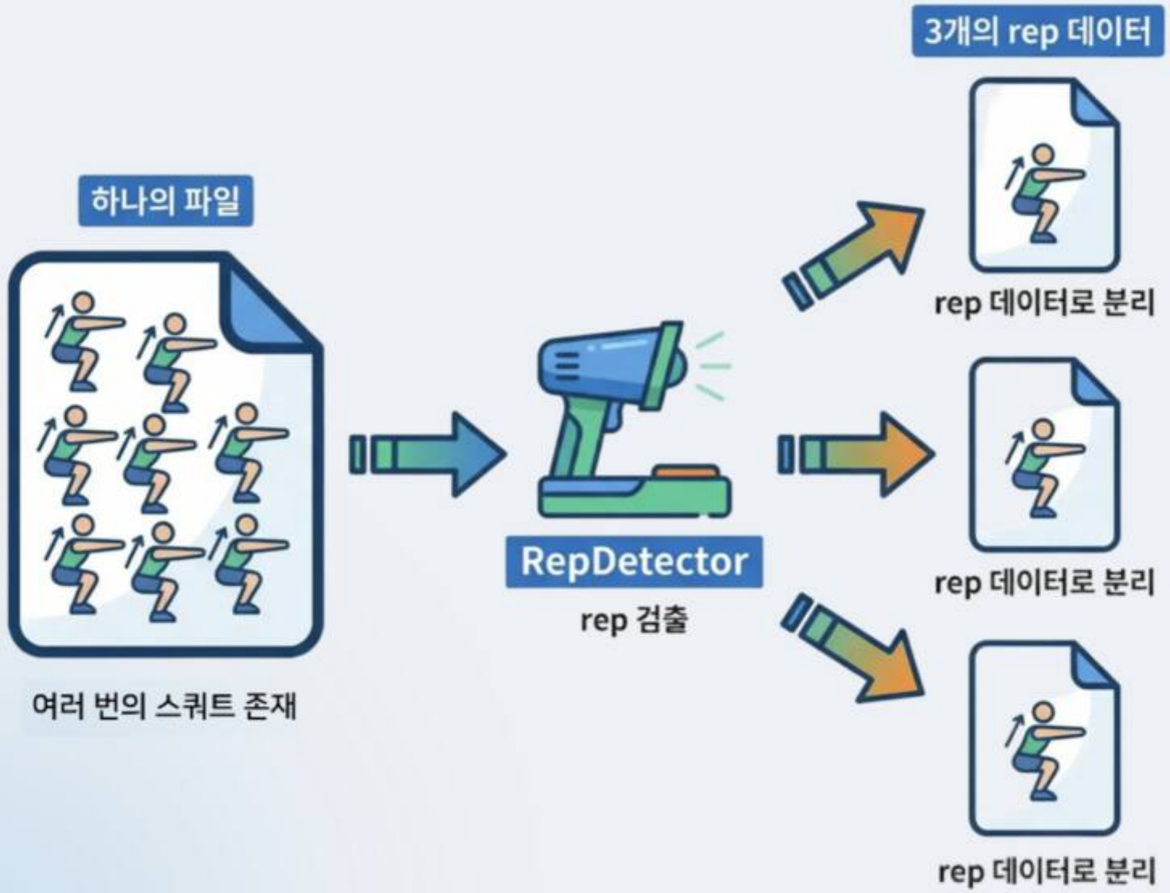
# 데이터 전처리 2) 데이터 증강



3

# 데이터 전처리 2) Rep 분리




**문제 상황**

하나의 json 파일 - 여러 번의 스쿼트 존재

동작마다 정밀한 진단을 내리기 위해
각각의 스쿼트 분리 필요성 인식

**해결**

top-peak-top 을 1 rep으로 분리

무릎 각도 볼 수 있는 측후면 시점의 데이터로
rep_index를 생성 후, 정면 시점의 데이터에
동일하게 적용

3

# 데이터 전처리 3) Input length 통일

이전 단계까지의 문제점:  분리된 Rep은 각자 프레임 수가 다름

**과정**

각 rep 파일에
선형보간 + 스무딩 적용



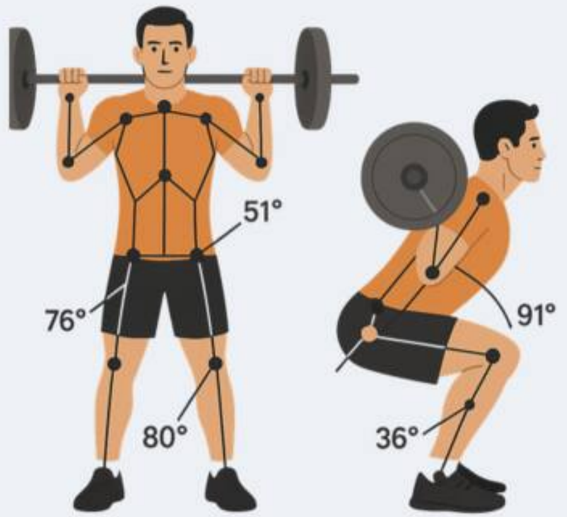
**최종 '좌표' 데이터 결과**

- View1 json 1790개 (각 64프레임)
- View3 json 1790개 (각 64프레임)

모델 Input을 동일한 길이로 통일

4

# 피처 엔지니어링




좌표를 각도로 변환 + rule-based 추가 라벨링 작업

4

# 사용할 각도와 계산 로직

## 측후면 view

1. 무릎 굴곡 각도 (Knee Flextion Angle
2. 엉덩이 굴곡 각도 (Hip Flextion Angle)
3. 발목 배측굴곡 각도 (Ankle Dorsiflextion Angle)
4. 몸통 전경사 각도 (Trunk Inclination Angle)
5. 경골(정강이) 기울기 각도 (Tibia Inclination Angle)

스쿼트 가동범위, 척추 중립, 발바닥 지면 고정 판단

## 정면 view

6. 무릎 valgus 각도 (Frontal Plane Projection Angle)
7. 골반 기울기 (Pelvic Tilt, frontal)
8. 몸통 좌우 기울기 (Trunk Lateral Tilt)
9. 무릎 vs 발 폭 비율 (Knee width ratio,
   Medial knee collapse proxy)

무릎과 발의 방향 일치, 고개 정면 응시 판정

# 모델 선정 및 아키텍처 구현

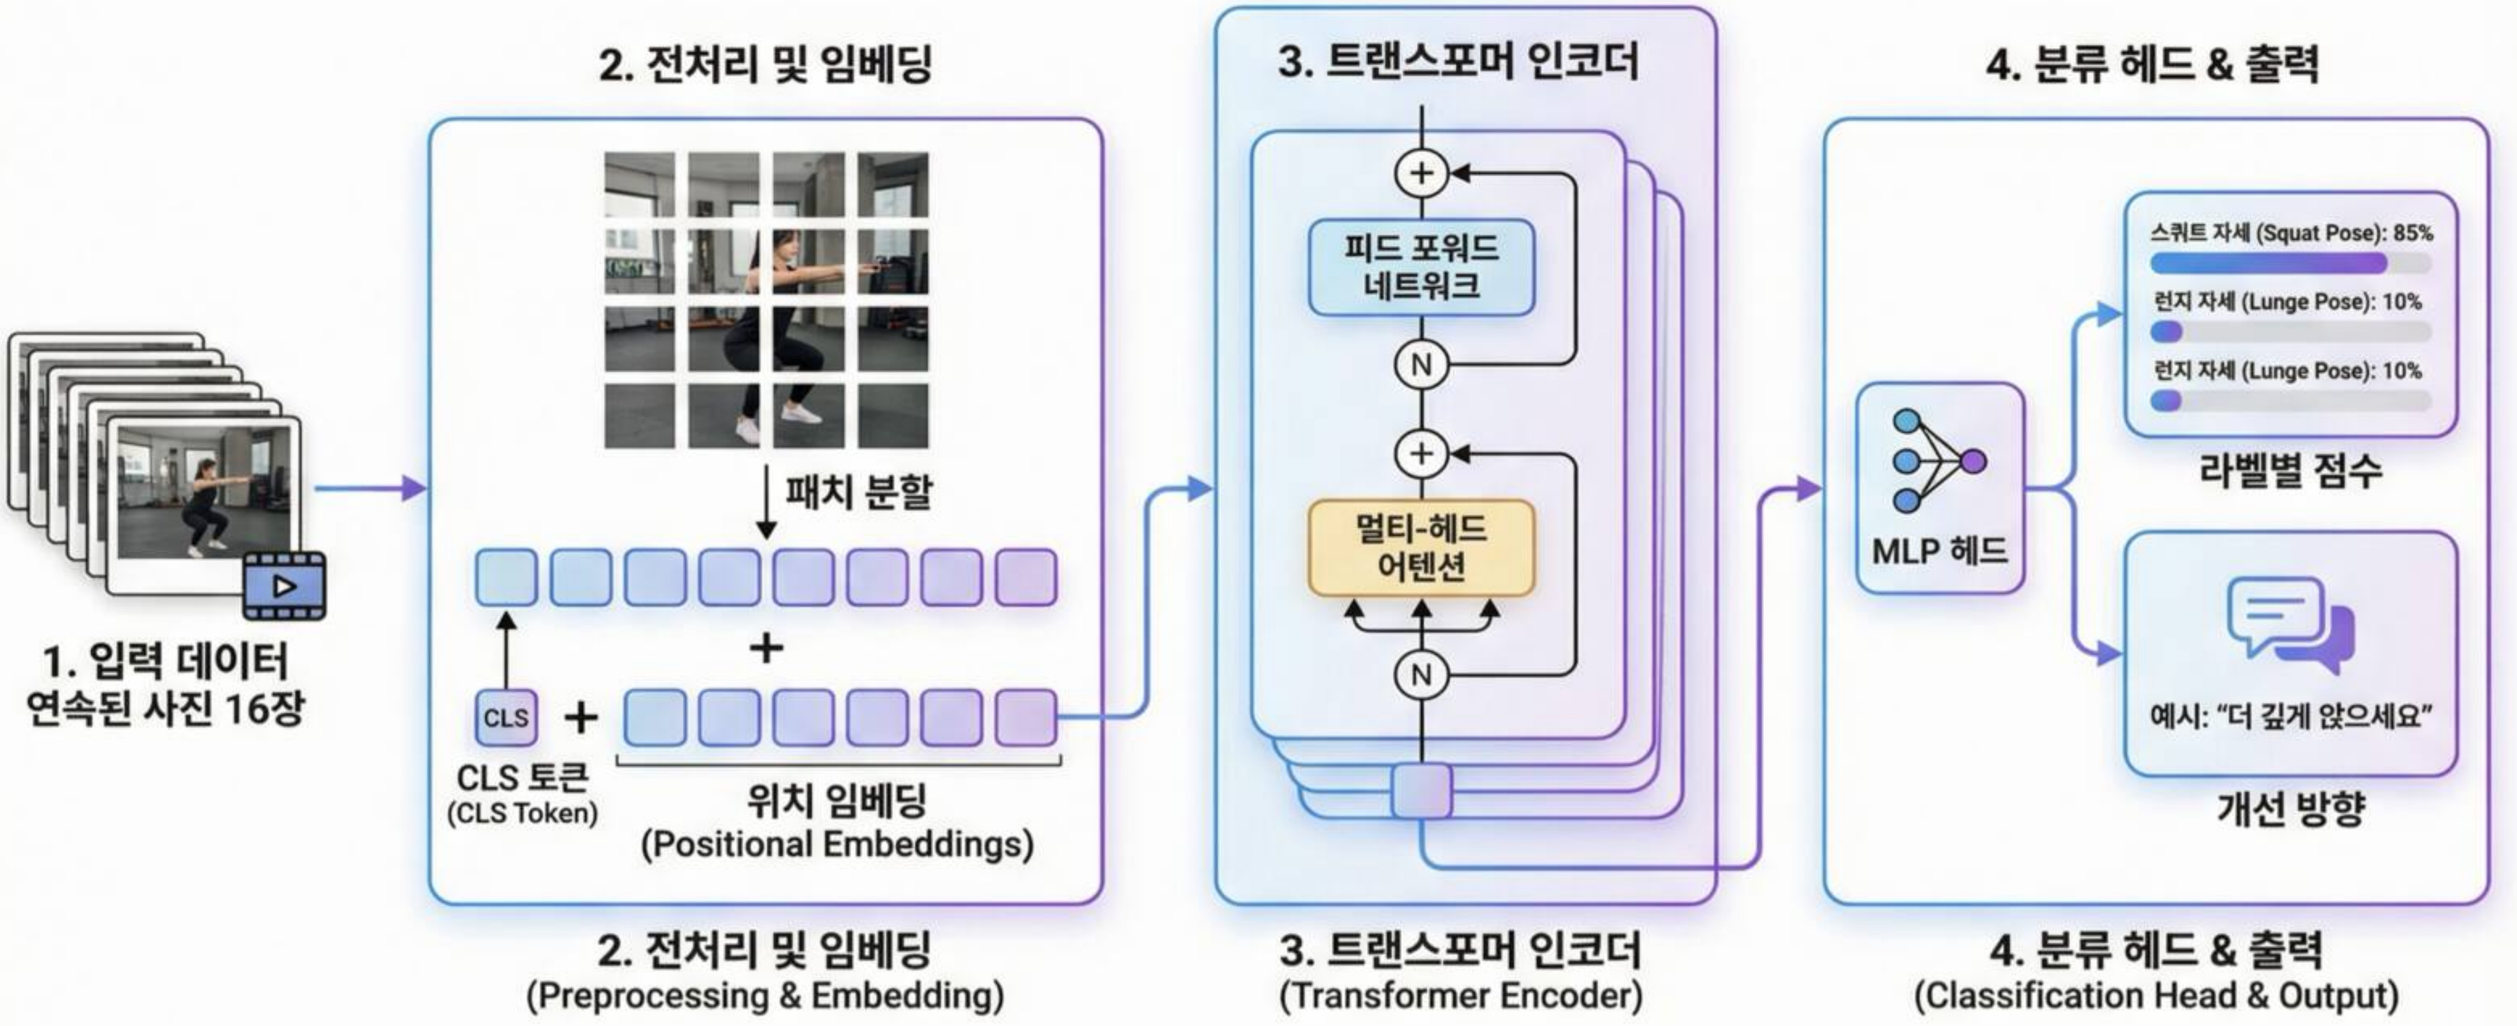
ViT model



LSTM model



# ViT model


1. 입력 데이터
연속된 사진 16장
2. 전처리 및 임베딩
패치 분할
CLS
CLS 토큰
(CLS Token)
위치 임베딩
(Positional Embeddings)
2. 전처리 및 임베딩
(Preprocessing & Embedding)
3. 트랜스포머 인코더
피드 포워드
네트워크
N
멀티-헤드
어텐션
N
3. 트랜스포머 인코더
(Transformer Encoder)
4. 분류 헤드 & 출력
MLP 헤드
스쿼트 자세 (Squat Pose): 85%
런지 자세 (Lunge Pose): 10%
런지 자세 (Lunge Pose): 10%
라벨별 점수
예시: "더 깊게 앉으세요"
개선 방향
4. 분류 헤드 & 출력
(Classification Head & Output)

5

# ViT - 데이터 처리

**데이터 처리**

Training data json 파일 720개
-> Training:Validation = 4:1

Validation data json 파일 112개
-> Test dataset으로 사용
VideoMAE 기본 processor로 전처리 진행

5

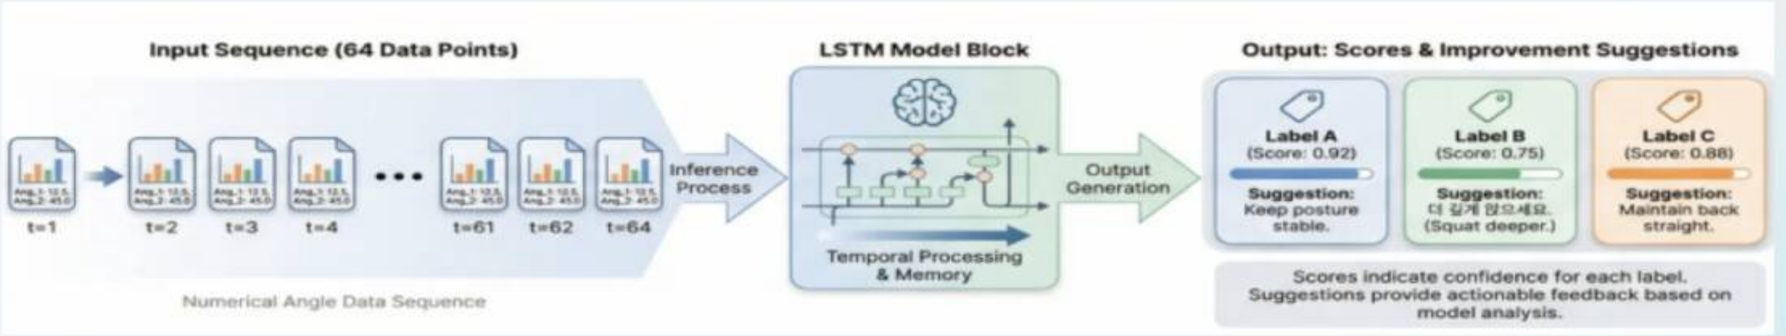
# ViT - 결과

| 측후면 | | | |
|---|---|---|---|
| 기준 | ROC-AUC | F1-score | Accuracy |
| 척추 중립 | 0.7950 | 0.6923 | 0.7143 |
| 고개 정면 | 0.7650 | 0.5854 | 0.6964 |
| 무릎 방향 | 0.9652 | 0.9483 | 0.9464 |
| 발바닥 고정 | 0.7156 | 0.7068 | 0.6518 |

| 정면 | | | |
|---|---|---|---|
| 기준 | ROC-AUC | F1-score | Accuracy |
| 척추 중립 | 0.7167 | 0.6885 | 0.6607 |
| 고개 정면 | 0.7041 | 0.6667 | 0.6696 |
| 무릎 방향 | 0.9015 | 0.7748 | 0.7768 |
| 발바닥 고정 | 0.8607 | 0.8160 | 0.7946 |

5

# LSTM




## 모델 선정 이유

- 연속적인 스쿼트 동작 -> 시계열 특화 모델
- 모바일에서 실시간으로 자세를 피드백하기에 적합

## 추가 설정

정면 영상 : 각도 변화가 미세

- > hidden 2배 & Layer 2층
- > 모델 자체 체급을 늘림

## 하이퍼파라미터 설정

view1 : INPUT(10)→LSTM(HIDDEN 64,LAYER1)→LayerNorm→FC(3)

view3 : INPUT(6)→LSTM(Hidden 128, Layer 2)→LayerNorm→FC(2)

6

# Test 환경 구축

MediaPipe 적용한
좌표 추출

Rep 분리 및
증강 or 압축

각도 계산 및
최종 추론 데이터 생성

# 주요 작업: 가려짐 보정




## 문제 상황

학습 데이터 : 정교한 영상
실제 사용자가 입력하는 영상 : 구도나 장애물에 따라 신체 일부 가려짐
- > 특히 가까운 쪽 다리에 의해, 먼 쪽 다리가 가려짐
- > 무릎 관련 각도가 계산이 불가능한 문제

## 해결

top-peak-top 을 1 rep으로 분리

무릎 각도 볼 수 있는 측후면 시점의 데이터로 rep_index를 생성
- > 정면 시점의 데이터에 동일하게 적용

# TEST PIPELINE: 사용자 입력 → 모델 추론 결과

## 1. 사용자 영상 촬영 및 업로드



구도에 맞춰 촬영

## 2. 프레임 단위 좌표 추출



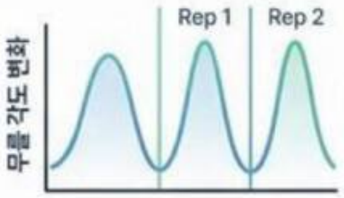

MediaPipe 활용

## 3. 각도 계산




좌표 기반

## 4. Repetition (반복) 분리




무릎 각도 변화 추적

## 5. 데이터 증강/압축



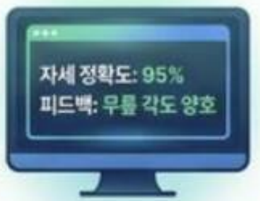

64프레임으로 표준화

## 6. 모델 입력 데이터 변환




모델 추론 최적화

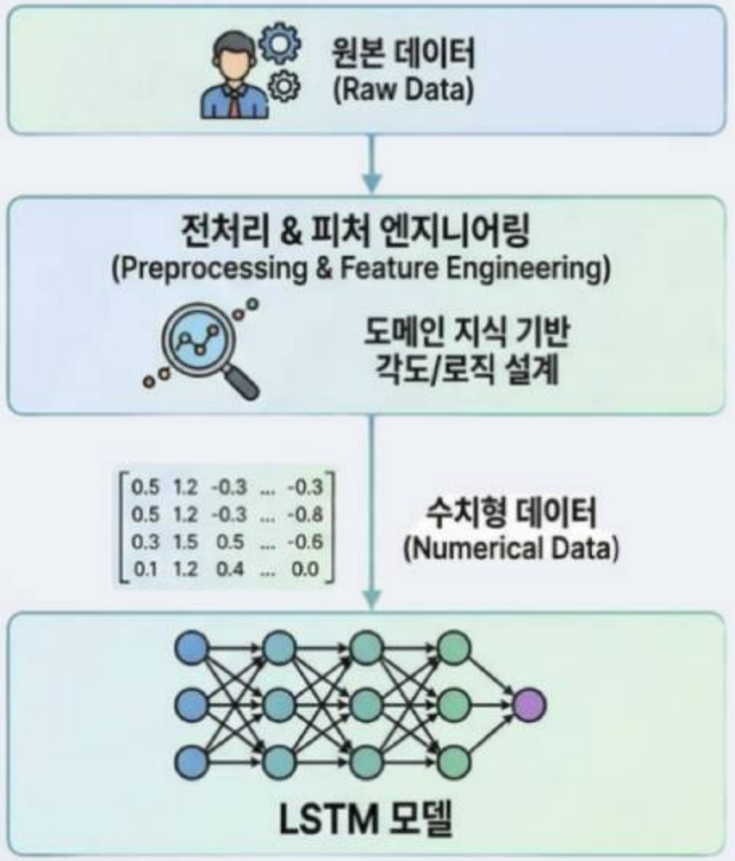
## 최종: 모델 추론 결과 출력



7

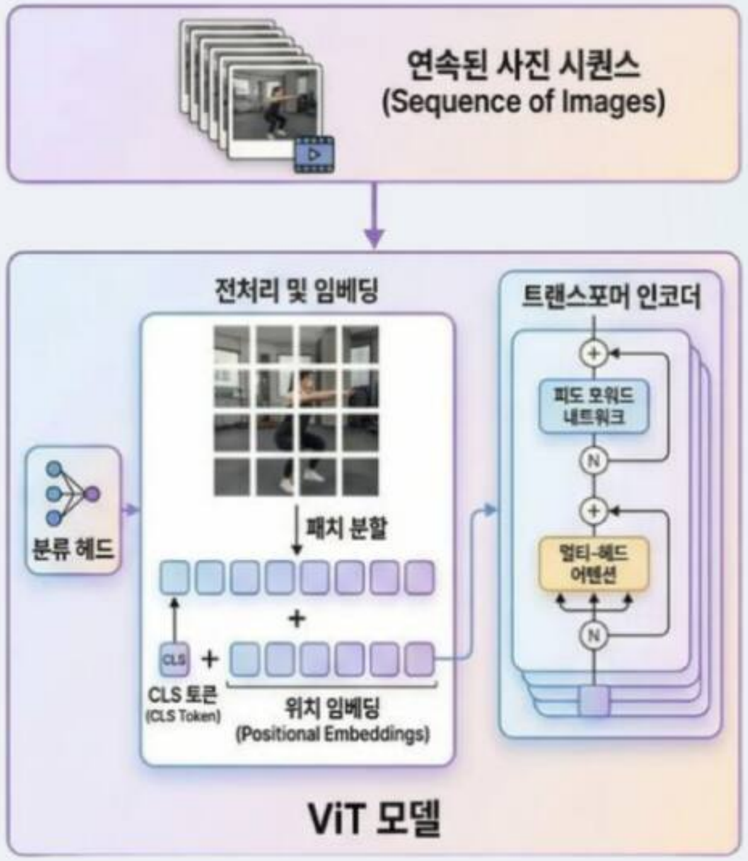
# 모델 비교

## 전처리 및 피처 엔지니어링 + LSTM 모델 (도메인 지식 기반)




특징 : 직접 특성 추출
장점 : CPU 학습 / 추론 속도 빠름 / 경량화

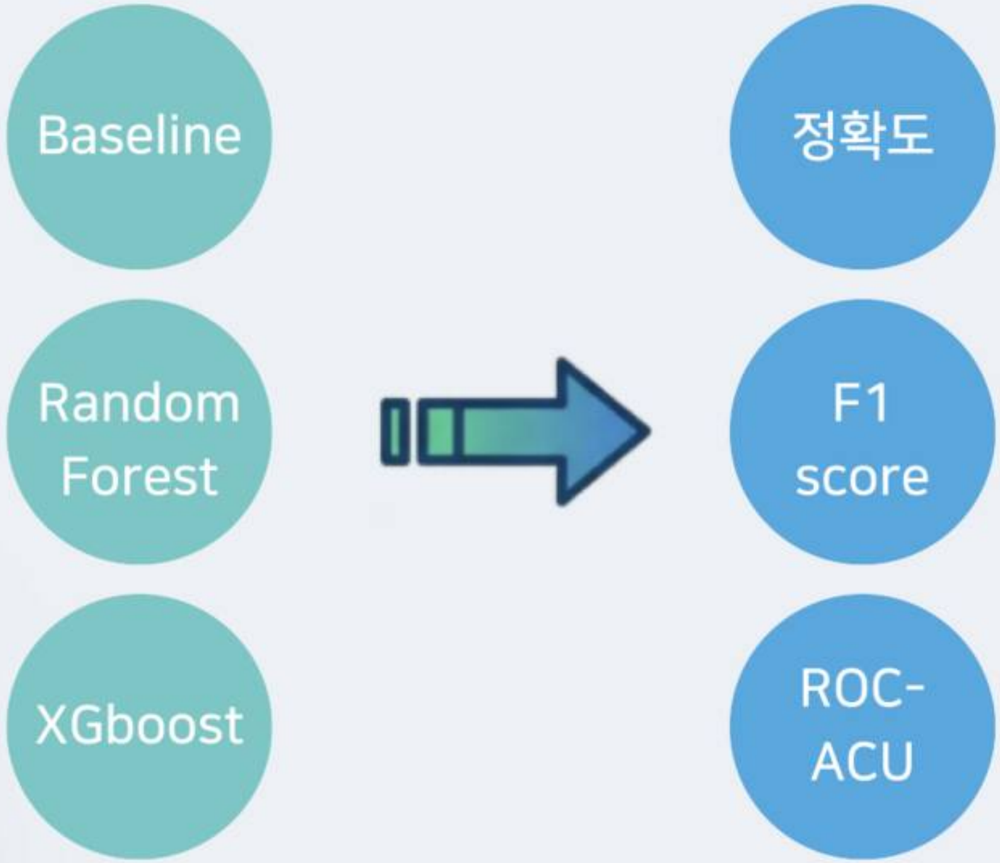
## 원본 사진 시퀀스 + ViT 모델 (자동 피처 추출)




특징 : 원본 데이터 활용
장점 : 피쳐 엔지니어링 불필요 / 자동 피쳐 생성

8

# 평가지표



9

# 모델 평가지표 비교

## 측후면

| F1-score | | | | |
|---|---|---|---|---|
| 평가항목 | 랜포 | XGboost | LSTM | ViT |
| 척추의 중립 | 0.776 | 0.8093 | 0.7055 | 0.6923 |
| 발바닥 지면 고정 | 0.7004 | 0.7365 | 0.8118 | 0.7068 |
| 가동범위 | 0.9007 | 0.959 | 0.808 | |
| | | | | |
| 정확도 | | | | |
| 평가항목 | 랜포 | XGboost | LSTM | ViT |
| 척추의 중립 | 0.7394 | 0.7758 | 0.755 | 0.7143 |
| 발바닥 지면 고정 | 0.7485 | 0.7636 | 0.806 | 0.6518 |
| 가동범위 | 0.8758 | 0.9515 | 0.855 | |
| | | | | |
| ROC-AUC | | | | |
| 평가항목 | 랜포 | XGboost | LSTM | ViT |
| 척추의 중립 | 0.8334 | 0.8698 | 0.8144 | 0.795 |
| 발바닥 지면 고정 | 0.8675 | 0.8661 | 0.8557 | 0.7156 |
| 가동범위 | 0.9563 | 0.9895 | 0.9472 | |

## 정면

| F1-score | | | |
|---|---|---|---|
| 평가항목 | 랜포 | XGboost | LSTM |
| 고개정면 | 0.7091 | 0.6825 | 0.7048 |
| 발-무릎 방향 | 0.9205 | 0.9169 | 0.8911 |
| | | | |
| 정확도 | | | |
| 평가항목 | 랜포 | XGboost | LSTM |
| 고개정면 | 0.7091 | 0.6758 | 0.718 |
| 발-무릎 방향 | 0.9152 | 0.9121 | 0.9 |
| | | | |
| ROC-AUC | | | |
| 평가항목 | 랜포 | XGboost | LSTM |
| 고개정면 | 0.7979 | 0.7882 | 0.7951 |
| 발-무릎 방향 | 0.9749 | 0.964 | 0.9506 |

10

# 결과

| 평가 항목 | 동작 구분 | XGBoost(평균) | LSTM(평균) | 분석 결과 |
|---|---|---|---|---|
| 척추의 중립 | 영상1 | 58.5점(주의) | 76.5점(양호) | LSTM이 동작의 흐름을 파악하여 더 관대하고 안정적으로 평가함 |
| | 영상2 | 83.8점(완벽) | 87.5점(완벽) | |
| 발바닥 지면 고정 | 영상1 | 16.5점(교정) | 1.0점(양호) | 가장 큰 격차<br>LSTM은 해당 동작을 더욱 엄격하게 판단 |
| | 영상2 | 65.8점(양호) | 35.2점(양호) | |
| 고개 정면 | 영상2 | 44.0점(주의) | 64.4점(양호) | LSTM이 시선 처링 대해 더 긍정적인 평가를 내림 |
| 가동범위 / 무릎 | 공통 | ~99점 | ~99점 | 단순 각도 계산 항목은 두 모델 모두 완벽하게 잡아냄 |

# 원인 추론

Q1) 척추 & 고개 평가에서 LSTM이 더 우수?

A1) 운동 중 '척추의 중립'은 특성 순간 흔들리더라도 '전체적인 흐름'이 중요하다!!

| | |
|---|---|
| XGboost | 프레임 단위(단편적 특징)으로 학습 |
| LSTM | 시계열 데이터 학습 |

Q2) 발바닥 고정 평가에서 LSTM이 가혹???

| | |
|---|---|
| XGboost | 특정 시점의 좌표 이탈 값만 평균 or<br>트리 분기점을 통과했는가 를 판단 (떨림 = 허용범위) |
| LSTM | 미세한 떨림이 시간 축으로 지속될 경우 '고정되지 않음' 으로 인식 |

=> 데이터 전처리 단계에서 노이즈 제거 / 허용 임계값 조정

12

# 발전 방향

평가 항목의 성격에 따라
다른 모델 적용  가능

앙상블 기법 도입

데이터가 풍부해지면
딥러닝 성능 향상

# QR 코드로 시연??

# Q & A

# 감사합니다.

